Duale Hochschule Baden-Württemberg Mannheim

**Projektarbeit 1**

# Entwicklung eines Prototyps zur Erkennung von Dateninkonsistenzen in SAP-Stücklisten mittels Machine Learning – am Beispiel der ABB AG, Standort Heidelberg

Studiengang

**Data Science und Künstliche Intelligenz**


| | |
|---|---|
| Verfasser: | Khalil Said Albert |
| Matrikelnummer: | 7630678 |
| Firma: | ABB AG Mannheim |
| Abteilung: | DE-IS |
| Kurs: | WDSKI25A |
| Studiengangsleiter: | Prof. Dr.-Ing. habil. Dennis Pfisterer |
| Wissenschaftlicher Betreuer: | Prof. Dr.-Ing. habil. Dennis Pfisterer |
| Firmenbetreuer: | Philipp Hörner |
| Bearbeitungszeitraum: | 17.08.2026 – 29.10.2026 |
| Abgabedatum: | 09.11.2026 |


*Arbeitsstand: Die Firmenangabe ist noch zu prüfen.*

# Ehrenwörtliche Erklärung

Ich versichere hiermit, dass ich die vorliegende Arbeit mit dem Titel "*Entwicklung eines Prototyps zur Erkennung von Dateninkonsistenzen in SAP-Stücklisten mittels Machine Learning – am Beispiel der ABB AG, Standort Heidelberg*" selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Ich versichere zudem, dass die eingereichte elektronische Fassung mit der gedruckten Fassung übereinstimmt.

Ort, Datum

Khalil Said Albert

# Hinweis zu Personenbezeichnungen

Personenbezeichnungen in dieser Arbeit beziehen sich auf alle Geschlechter. Bei der Wahl der Bezeichnungen steht eine verständliche und einheitliche Sprache im Vordergrund.

# Sperrvermerk

*Entwurf: Die Notwendigkeit und der Wortlaut des Sperrvermerks sind noch mit dem Unternehmen abzustimmen.*

Der Inhalt dieser Arbeit darf weder als Ganzes noch in Auszügen Personen außerhalb des Prüfungsprozesses und des Evaluationsverfahrens zugänglich gemacht werden, sofern keine anders lautende Genehmigung der Ausbildungsstätte vorliegt.

# Inhaltsverzeichnis

**1 Einleitung** **1**

1.1 Motivation und Ziel . . . . . 1

1.2 Forschungsfrage und Abgrenzung . . . . . 2

1.3 Vorgehensweise und Aufbau der Arbeit . . . . . 3

**3 Datenbasis und Anforderungen** **4**

3.1 Datenbasis und Besonderheiten der Stücklisten . . . . . 4

3.2 Anforderungen an den Prototyp . . . . . 5

**4 Forschungsstand und Methodenwahl** **6**

4.1 Verwandte Ansätze zur Stücklistenanalyse . . . . . 6

4.2 Einordnung anhand der Anforderungen . . . . . 8

4.3 Begründung des eigenen Ansatzes . . . . . 9

**Literaturverzeichnis** **11**

# Kapitel 1

# Einleitung

## 1.1 Motivation und Ziel

Eine Stückliste (engl. *Bill of Materials*, kurz BOM) beschreibt, welche Komponenten in welchen Mengen zur Herstellung eines Produkts vorgesehen sind [vgl. 1, S. 3]. Fehlerhafte Einträge in Stücklisten können dazu führen, dass die hinterlegten Daten im System vom tatsächlichen Materialbedarf abweichen. Mögliche Fehler sind beispielsweise fehlende oder unpassende Komponenten sowie falsche Mengenangaben.

Fehlerhafte Stücklistendaten können sich auf die Bestandsführung auswirken, also auf die Erfassung der vorhandenen Materialbestände im System. Damit die Bestandsangaben mit dem tatsächlich vorhandenen Material übereinstimmen, muss der Materialverbrauch korrekt gebucht werden. Bei der retrograden Entnahme (engl. *backflushing*) wird der Verbrauch der dafür vorgesehenen Komponenten bei der Produktionsrückmeldung automatisch gebucht [vgl. 2]. Die hinterlegten Stücklistendaten dienen dabei als Grundlage [vgl. 3]. Sind dort falsche Komponenten oder Mengen hinterlegt, kann der gebuchte Verbrauch vom tatsächlichen Verbrauch abweichen. Dadurch kann der im System geführte Bestand vom tatsächlich vorhandenen Bestand abweichen.

Um solche Fehler zu erkennen, muss zwischen fehlerhaften Einträgen und korrekten Produktvarianten unterschieden werden. Auch innerhalb einer Produktgruppe können unterschiedliche Komponenten und Mengen fachlich korrekt sein. Eine Kombination, die im untersuchten Datenbestand nur einmal vorkommt, kann ebenfalls fachlich korrekt sein. Deshalb reicht die Seltenheit eines Eintrags allein nicht aus, um ihn als Inkonsistenz zu bewerten. Entscheidend ist, ob eine Komponente oder Menge im Zusammenhang mit dem jeweiligen Produkt plausibel ist [vgl. 4, Abschnitt 2.2.2].

Bei der Prüfung einer Stückliste sollen ihre Komponenten und Mengen im Zusammenhang mit dem jeweiligen Produkt bewertet werden. Mit Machine Learning sollen aus den vorhande-

nen Stücklistendaten typische Muster gelernt werden, um auffällige Abweichungen in der zu prüfenden Stückliste zu erkennen. Solche Abweichungen von erwarteten Mustern werden als Anomalien bezeichnet [vgl. 4, Abschnitt 1.1]. Die Anomalieerkennung soll damit Hinweise auf mögliche Inkonsistenzen liefern, die anschließend durch den zuständigen Fachbereich bewertet werden können.

Ziel dieser Arbeit ist die Entwicklung, Implementierung und Evaluation eines Prototyps zur Erkennung möglicher Dateninkonsistenzen in SAP-Stücklisten. Die Untersuchung erfolgt anhand von Stücklistendaten der ABB AG am Standort Heidelberg. Der Prototyp soll auffällige Komponenten und Mengen als priorisierte Liste von Prüfkandidaten ausgeben. Für jeden Kandidaten soll dargestellt werden, welcher Eintrag auffällig ist und auf welchen Vergleichsinformationen die Bewertung beruht. Ob tatsächlich eine Inkonsistenz vorliegt, beurteilt der zuständige Fachbereich. Die Evaluation untersucht, in welchem Umfang der Prototyp Inkonsistenzen erkennt, welche Fehlalarme entstehen und wie sich das Verfahren auf weitere Stücklisten übertragen lässt.

## 1.2 Forschungsfrage und Abgrenzung

Aus dem Ziel, mögliche Inkonsistenzen unter Berücksichtigung der Zusammenhänge in Stücklistendaten zu erkennen, ergibt sich folgende Forschungsfrage:

> *Inwieweit lassen sich Dateninkonsistenzen in SAP-Stücklisten anhand von Zusammenhängen erkennen, die mit Machine Learning aus den Stücklistendaten gelernt werden?*

Die Untersuchung konzentriert sich auf die bereitgestellten Stücklistendaten der ABB AG am Standort Heidelberg. Betrachtet werden die in einer Stückliste enthaltenen Komponenten und ihre Mengen sowie die Zusammenhänge zwischen diesen Einträgen. Zu prüfen ist beispielsweise, ob eine Komponente für die Zusammensetzung des jeweiligen Produkts passt oder eine Mengenangabe von den erwarteten Werten abweicht. Der Prototyp soll diese Einträge zur fachlichen Prüfung auswählen und priorisieren. Eine automatische Korrektur der Daten oder eine produktive Integration in SAP ist erstmals nicht Gegenstand dieser Arbeit.

Für die Beantwortung der Forschungsfrage muss zwischen einer vom Modell erkannten Auffälligkeit und einer fachlich bestätigten Inkonsistenz unterschieden werden. Die Bewertung berücksichtigt deshalb sowohl bestätigte Fehler als auch Fehlalarme. Seltene, fachlich korrekte Produktvarianten sind dabei zu berücksichtigen. Aussagen zur Übertragbarkeit des Verfahrens werden auf den tatsächlich untersuchten Daten- und Anwendungsumfang begrenzt.

## 1.3 Vorgehensweise und Aufbau der Arbeit

Der Prototyp wird schrittweise entwickelt. Dazu werden die bereitgestellten Stücklistendaten bereinigt und in eine passende Form für die Modelle gebracht. Die Modelle sollen aus diesen Daten lernen, welche Komponenten und Mengen im Zusammenhang mit dem jeweiligen Produkt zu erwarten sind. Die Modellergebnisse werden zunächst von mir überprüft. Ausgewählte auffällige Einträge werden anschließend durch den Fachbereich geprüft. Anhand der fachlich bestätigten Fehler lässt sich prüfen, ob die Modelle diese Einträge als auffällig erkennen. Dieser iterative Ablauf aus Entwicklung, Prüfung und Anpassung soll die Qualität der Modellergebnisse verbessern.

# Kapitel 3

# Datenbasis und Anforderungen

Dieses Kapitel stellt die untersuchten Stücklistendaten und ihre Besonderheiten vor. Darauf aufbauend werden die Anforderungen an den Prototyp festgelegt.

## 3.1 Datenbasis und Besonderheiten der Stücklisten

Für die Untersuchung werden bereitgestellte SAP-Stücklistenexports der ABB AG am Standort Heidelberg verwendet. Jede Position ordnet einem Produkt eine Komponente mit einer Mengenangabe und einer Mengeneinheit zu. Die Felder Identnummer und Materialkurztext beziehen sich auf das Produkt; der Zusatz „Teil“ kennzeichnet die entsprechenden Angaben zur Komponente. Tabelle 3.1 zeigt die wesentlichen Felder des Exports und ihre Bedeutung.

| **Feld im Export** | **Bedeutung** |
|---|---|
| Identnummer / Identnummer Teil | Materialnummern des Produkts und der Komponente. |
| Materialkurztext / Materialkurztext Teil | Bezeichnungen des Produkts und der Komponente. |
| Menge | Mengenangabe der Komponente. |
| Stufe | Ebene einer Position innerhalb der Stücklistenstruktur. |

Tabelle 3.1: Wesentliche Felder des Stücklistenexports; eigene Zusammenstellung.

Auch innerhalb derselben Produktgruppe können sich die benötigten Komponenten und Mengen je nach Produktausführung unterscheiden. Grund hierfür sind die unzähligen Varianten, die ein Produkt haben kann.

## 3.2 Anforderungen an den Prototyp

Die folgenden Anforderungen legen fest, welche Abweichungen der Prototyp erkennen und wie er die fachliche Prüfung unterstützen soll. Die Anforderungen werden nummeriert, damit später für jeden Punkt geprüft werden kann, ob er erfüllt wurde.

**A1 – Fehlende oder unpassende Komponenten.** Der Prototyp soll Hinweise auf fehlende oder unpassende Komponenten liefern und beide Fälle in der Ausgabe unterscheiden.

**A2 – Abweichende Mengen.** Der Prototyp soll auffällige Mengenangaben erkennen. Dabei soll er berücksichtigen, welche Mengen für die Zusammensetzung des jeweiligen Produkts zu erwarten sind.

**A3 – Umgang mit Produktvarianten.** Die Bewertung soll Unterschiede zwischen Produktausführungen berücksichtigen. Eine seltene Komponente oder Kombination darf nicht allein wegen ihrer Seltenheit als Fehler gemeldet werden.

**A4 – Verständliche Begründung der Auffälligkeiten.** Die Ausgabe soll die auffälligsten Kandidaten zuerst anzeigen. Die gefundene Abweichung soll verständlich beschrieben werden, zusätzlich sollen Belege und Vergleichsinformationen bereitgestellt werden, die eine fachliche Prüfung ermöglichen.

**A5 – Möglichst wenige Fehler übersehen.** Der Prototyp soll möglichst wenige tatsächliche Fehler übersehen (engl. *False Negatives*, FN). Dafür werden zusätzliche Fehlalarme (engl. *False Positives*, FP) eher in Kauf genommen. Ein Fehlalarm kann bei der fachlichen Prüfung verworfen werden, während ein übersehener Fehler in der Stückliste bleibt.

**A6 – Anwendung auf unterschiedliche Stücklisten.** Das Verfahren soll auf unterschiedliche Stücklisten übertragbar sein. Die Prüfung soll auf Zusammenhängen beruhen, die aus den jeweiligen Stücklistendaten gelernt werden, ohne spezifische Regeln einzubauen.

# Kapitel 4

# Forschungsstand und Methodenwahl

Die Anforderungen aus Kapitel 3 bilden die Grundlage für die Methodenwahl. Dazu werden ausgewählte Arbeiten betrachtet, die sich mit unterschiedlichen Aufgaben mit Stücklistendaten beschäftigt haben. Anschließend wird begründet, wie die Fehlererkennung in der vorliegenden Arbeit umgesetzt wird.

## 4.1 Verwandte Ansätze zur Stücklistenanalyse

Romanowski und Nagi vergleichen Stücklisten, um ähnliche Produkte zu Produktfamilien zusammenzufassen. Dazu stellen sie ein Produkt mit seinen Baugruppen und Einzelteilen als Baum dar. Abbildung 4.1 veranschaulicht diese Zuordnung an einer vereinfachten Stückliste für einen Bürostuhl: Sitz und Untergestell sind dabei die Baugruppen. Komponenten wie Polster und Sitzrahmen gehören zum Sitz, die Rollen zum Untergestell.

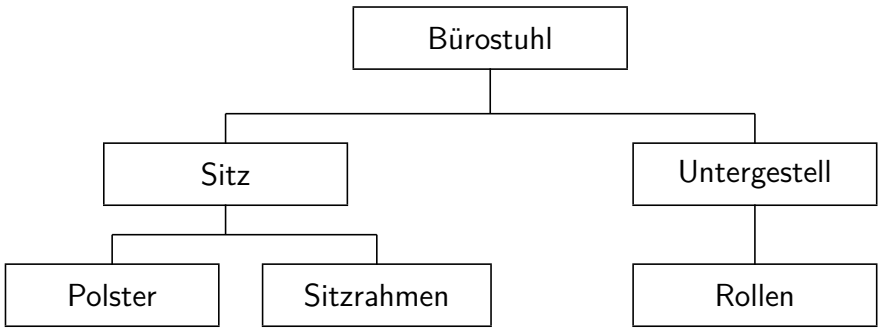



Abbildung 4.1: Vereinfachte Stückliste eines Bürostuhls als Baum; eigene Darstellung in Anlehnung an [5, Abbildung 1].

Ob Sitz und Untergestell links oder rechts nebeneinander dargestellt werden, ändert die Zusammensetzung nicht. Enthält dagegen nur eine der beiden verglichenen Stücklisten ein Polster,

unterscheiden sich ihre Komponenten. Die Struktur unterscheidet sich, wenn das Polster in einer Stückliste zum Sitz gehört und in der anderen zum Untergestell [vgl. 5, Abschnitt I].

Aus den Unterschieden der Komponenten und ihrer Zuordnung berechnen die Autoren einen Abstand zwischen den Stücklisten. Anhand dieser Abstände werden ähnliche Produkte zu Produktfamilien gruppiert. Für dieses Clustering verwenden die Autoren das k-Medoids-Verfahren [vgl. 5, Abschnitte I und V]. Die Stücklistendarstellung der Autoren erfasst außerdem Mengenangaben [vgl. 5, Abschnitt II.D].

Im Prototyp werden Produkte innerhalb desselben Stücklistenexports anhand ihrer gemeinsamen Komponenten verglichen. Die Vergleiche liefern Merkmale (engl. *features*) für die Modelle, etwa den Anteil ähnlicher Produkte mit einer Komponente oder typische Mengen für eine Komponente. Diese Vergleichsinformationen werden ebenfalls als Gründe für die Entscheidung des Prototyps in der Kandidatenliste angezeigt. Das Distanzverfahren von Romanowski und Nagi wird dabei nicht verwendet.

Frey, May und Lanza lernen aus Beispielstücklisten, welche Komponenten zu gewählten Produkten gehören. Die gelernten Zusammenhänge bilden ein konfigurierbares System, das für ein ausgewähltes Produkt eine passende Stückliste ableitet. Das System wird aus Regeln zusammengestellt, die der Anwender bearbeiten und ergänzen kann [vgl. 6, Abschnitt 3.4].

Für die vorliegende Arbeit ist besonders die zusätzliche Prüfung dieser Lernbeispiele relevant. Dabei untersuchen die Autoren sowohl die Beziehungen zwischen Produkteigenschaften und Komponenten als auch Kombinationen mehrerer Komponenten. Die Beispiele werden durch Clustering gruppiert und auf Ausreißer geprüft. Kommen zwei Komponenten gewöhnlich gemeinsam vor, kann eine Stückliste auffallen, die nur eine davon enthält. Eine solche Abweichung kann einen technischen Grund haben oder auf einen Fehler hinweisen. Die gemeldeten Auffälligkeiten müssen deshalb manuell geprüft werden [vgl. 6, Abschnitt 3.5].

Bei Frey et al. dient diese Prüfung der Qualität der Beispieldaten, aus denen das Konfigurationssystem gelernt wird. Im Prototyp werden die bereitgestellten Stücklistendaten auf mögliche Komponenten- und Mengenfehler geprüft. Der gemeinsame Bezug liegt darin, die Angaben eines Produkts im Zusammenhang mit seinen Eigenschaften und den übrigen Komponenten zu bewerten.

Schramm, Pieper und Vogl untersuchen mögliche Stücklistenfehler während der Produktentwicklung. Sie betrachten dazu Stücklistenstände aus verschiedenen Zeitpunkten. Änderungen können beabsichtigt sein oder auf Fehler hinweisen. Ein berechneter Abstand beschreibt, wie stark sich die hierarchisch dargestellten Stücklistenstände unterscheiden. Isolation Forests, ML-Modelle zur Anomalieerkennung, markieren auffällige zeitliche Veränderungen; durch Clustering werden ähnliche Fälle gruppiert. Ein neuronales Netz ergänzt die Analyse um Vorhersagen, an welcher Stelle und zu welchem Zeitpunkt mögliche Stücklistenfehler zu erwarten sind [vgl. 7, Abstract].

Der Prototyp bewertet dagegen die Komponenten und Mengen innerhalb des jeweiligen Stücklistenexports. Für jeden untersuchten Export werden die Modelle erneut trainiert. Die Daten des jeweils geprüften Produkts bleiben dabei aus dem Training des zugehörigen Modells ausgeschlossen. Eine zeitliche Folge mehrerer Stücklistenstände wird als Modelleingabe nicht benötigt.

## 4.2 Einordnung anhand der Anforderungen

Gemeinsam ist den Ansätzen die Auswertung von Beziehungen innerhalb einer Stückliste oder zu Produktmerkmalen. Für den Prototyp sind insbesondere die Vergleiche ähnlicher Stücklisten und das Lernen typischer Komponentenkombinationen relevant. Tabelle 4.1 zeigt den Bezug dieser Beiträge zu den Anforderungen aus Kapitel 3.

| **Anforderung** | **Romanowski / Nagi** | **Frey et al.** | **Schramm et al.** |
|---|---|---|---|
| A1: Komponenten | Komponenten vergleichen | Anwesenheit lernen; Kombinationen prüfen | Fehler mit Zeitbezug vorhersagen |
| A2: Mengen | Mengen abbilden; keine Fehlerbewertung | Keine Mengenprüfung beschrieben | Nicht beurteilbar |
| A3: Varianten | Produktfamilien bilden | Produktmerkmale berücksichtigen | Ähnliche Fälle gruppieren |
| A4: Begründung | Keine Kandidatenbegründung beschrieben | Lesbare gelernte Regeln | Nicht beurteilbar |
| A5: Wenige Fehler übersehen | Kein Fehlererkennungsziel | FN-Priorisierung nicht belegt | Nicht beurteilbar |
| A6: Weitere Stücklisten | Übertragbarkeit hier nicht belegt | Übertragbarkeit hier nicht belegt | Nicht beurteilbar |

Tabelle 4.1: Bezug ausgewählter Ansätze zu den Anforderungen; eigene Einordnung nach [5, 6, 7]. „Nicht belegt“ bezieht sich auf die ausgewerteten Textstellen; „nicht beurteilbar“ auf Angaben, die Schramms Abstract offenlässt.

Mengen in einer Stückliste abzubilden genügt für Anforderung A2 noch nicht: Der Prototyp soll bewerten, ob eine hinterlegte Menge zur jeweiligen Produktzusammensetzung passt. Ebenso machen lesbare Regeln die Zuordnung von Komponenten verständlich, ersetzen aber noch

keine Begründung eines konkreten Prüfkandidaten nach Anforderung A4.

Die Ansätze setzen unterschiedliche Daten voraus: Romanowski und Nagi verwenden Stücklistenstrukturen und vorgegebene Informationen zur Ähnlichkeit von Teilen, Frey et al. benötigen Produktmerkmale und zugehörige Stücklisten, Schramm et al. Stücklistenstände aus mehreren Zeitpunkten [5, 6, 7]. Welche Daten ein Ansatz benötigt, zeigt noch nicht, wie zuverlässig er auf weiteren Stücklisten Fehler erkennt.

Die Evaluation des Prototyps untersucht anhand fachlich bestätigter Fehler und definierter Prüffälle, welche davon erkannt werden (Anforderung A5). Seine Anwendung auf weitere Stücklisten wird gesondert geprüft (Anforderung A6).

## 4.3 Begründung des eigenen Ansatzes

Für den Prototyp wird die Prüfung als Vorhersageaufgabe gestaltet. Bei einer betrachteten Komponente soll das Modell aus der übrigen Stücklistenzusammensetzung und dem Produktkontext lernen, ob ihre Anwesenheit zu erwarten ist. Für vorhandene Komponenten wird zusätzlich untersucht, welche Mengen zu diesem Zusammenhang passen. Die Vorhersagen werden mit den hinterlegten Angaben verglichen, um mögliche Abweichungen auszuwählen. Damit werden die Komponentenprüfung nach Anforderung A1 und die Mengenprüfung nach Anforderung A2 getrennt behandelt.

Als Lernziele dienen die in den Stücklisten beobachteten Komponenten- und Mengenzustände. Sie kennzeichnen den vorherzusagenden Zustand, nicht die fachliche Richtigkeit eines Eintrags. Die daraus gebildeten Vorhersageaufgaben werden mit Klassifikationsmodellen bearbeitet; diese lernen die Zuordnung von Eingabemerkmalen zu Zielklassen [vgl. 8, Abschnitt 1.2.1]. Für das Training ist deshalb keine vollständige Kennzeichnung aller Einträge als fehlerhaft oder korrekt erforderlich. Allerdings können auch vorhandene Fehler in die gelernten Zusammenhänge eingehen. Eine Abweichung zwischen Vorhersage und hinterlegtem Zustand muss daher weiterhin fachlich beurteilt werden.

Für die Vorhersagen wird CatBoost verwendet. Das Verfahren gehört zum Gradient Boosting und kombiniert mehrere Entscheidungsbäume zu einem Modell. Es unterstützt Klassifikationsaufgaben und die Verarbeitung kategorialer Merkmale [vgl. 9, Abschnitte 2–3]. Das passt zur tabellarischen Darstellung der Stücklisten: Die Modelleingaben enthalten unter anderem Angaben zur Anwesenheit von Komponenten sowie numerische und kategoriale Informationen. Eine Komponentenkennung bezeichnet dabei eine Kategorie; ihre Ziffern stellen keinen numerischen Abstand zwischen Materialien dar. Wie gut es auf den untersuchten Stücklisten funktioniert, wird in der Evaluation geprüft.

Die Vorhersagen sollen außerdem durch Informationen aus ähnlichen Stücklisten ergänzt wer-

den. Solche Vergleiche zeigen, welche Komponenten und Mengen in verwandten Produkten hinterlegt sind, und können die Prüfung eines Kandidaten unterstützen. Romanowski und Nagi liefern einen methodischen Bezug für solche Stücklistenvergleiche. Im Prototyp wird die Ähnlichkeit anhand gemeinsamer Komponenten bestimmt. Die konkrete Berechnung, die Auswahl der Vergleichsstücklisten und die Verwendung ihrer Informationen werden bei der Umsetzung erläutert.

Zur Erklärung einzelner Modellvorhersagen wird ergänzend SHAP eingesetzt. Die Methode ordnet den Eingabemerkmalen Beiträge zu einer Modellvorhersage zu [vgl. 10, Abschnitte 2–4]. Damit lässt sich untersuchen, welche Merkmale die jeweilige Vorhersage beeinflussen. Ein solcher Beitrag belegt für sich genommen weder einen tatsächlichen Stücklistenfehler noch eine Verbesserung der Vorhersagegüte.

Das folgende Kapitel beschreibt, wie die Exportdaten dafür aufbereitet und die Modelle bis zur Ausgabe der Kandidaten umgesetzt werden.

# Literaturverzeichnis


[1] SAP SE. *Glossary for the Joint use of SAP ERP and Siemens Teamcenter*. 21. Aug. 2023. 8 S. URL: https://help.sap.com/doc/04e4c853f83e4f558047000b9ffc8e06/2.0%20FP04/en-US/Teamcenter_Glossary.pdf (besucht am 02. 10. 2026).

[2] SAP SE. *Warenbewegungen bei der Rückmeldung. SAP S/4HANA: Fertigungsaufträge (PP-SFC), 2025 FPS01*. URL: https://help.sap.com/docs/SAP_S4HANA_ON-PREMISE/34de0103497c4b80a7c7fbf6952ff971/1604b753128eb44ce10000000a174cb4.html?locale=de-DE (besucht am 04. 10. 2026).

[3] SAP SE. *Backflushing with Component Correction. SAP ERP 6.0 EHP8: Repetitive Manufacturing (PP-REM)*. URL: https://help.sap.com/docs/SAP_ERP/4d35e322f79d4744abeda0b9caaab5a4/8e6bb6531de6b64ce10000000a174cb4.html (besucht am 02. 10. 2026).

[4] Varun Chandola, Arindam Banerjee und Vipin Kumar. „Anomaly Detection: A Survey“. In: *ACM Computing Surveys* 41.3, 15 (Juli 2009). DOI: 10.1145/1541880.1541882. URL: https://arindam.cs.illinois.edu/papers/09/anomaly.pdf (besucht am 02. 10. 2026).

[5] Carol J. Romanowski und Rakesh Nagi. „On Comparing Bills of Materials: A Similarity/Distance Measure for Unordered Trees“. In: *IEEE Transactions on Systems, Man, and Cybernetics, Part A: Systems and Humans* 35.2 (März 2005), S. 249–260. DOI: 10.1109/TSMCA.2005.843395. URL: https://www.eng.buffalo.edu/~nagi/papers/IEEESMCApaper.pdf (besucht am 07. 10. 2026).

[6] Alex Maximilian Frey, Marvin Carl May und Gisela Lanza. „Creation and Validation of Systems for Product and Process Configuration Based on Data Analysis“. In: *Production Engineering* 17 (2023), S. 263–277. DOI: 10.1007/s11740-022-01176-1. URL: https://link.springer.com/article/10.1007/s11740-022-01176-1 (besucht am 07. 10. 2026).

[7] Simon Schramm, Matthias Pieper und Stefanie Vogl. „Orthogonal Procrustes and Machine Learning: Predicting Bill of Materials Errors on Time“. In: *Computers & Industrial Engineering* 185, 109606 (Nov. 2023). DOI: 10.1016/j.cie.2023.109606. URL: https://www.sciencedirect.com/science/article/pii/S0360835223006307 (besucht am 07. 10. 2026).

[8] Andriy Burkov. *Machine Learning Engineering*. True Positive Incorporated, 2020. ISBN: 9781999579579. URL: https://books.google.de/books?id=HeXizQEACAAJ (besucht am 06. 10. 2026). Zitierte Textgrundlage: bereitgestellte Entwurfsfassung.

[9] Liudmila Prokhorenkova u. a. „CatBoost: Unbiased Boosting with Categorical Features“. In: *Advances in Neural Information Processing Systems*. Bd. 31. 2018. URL: https://proceedings.neurips.cc/paper_files/paper/2018/hash/14491b756b3a51daac41c24863285549-Abstract.html (besucht am 07. 10. 2026).

[10] Scott M. Lundberg und Su-In Lee. „A Unified Approach to Interpreting Model Predictions“. In: *Advances in Neural Information Processing Systems*. Bd. 30. 2017. URL: https://proceedings.neurips.cc/paper_files/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html (besucht am 07. 10. 2026).